eNOSE

AeroSense

SEP 23, 2026

NTHU iGEM x
China Medical University

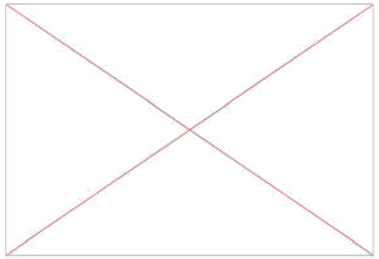
Guest Lecture

iGEM

全球最具指標性的合成生物學競賽，由 **MIT** 發起，希望運用合成生物學解決實際世界的問題。





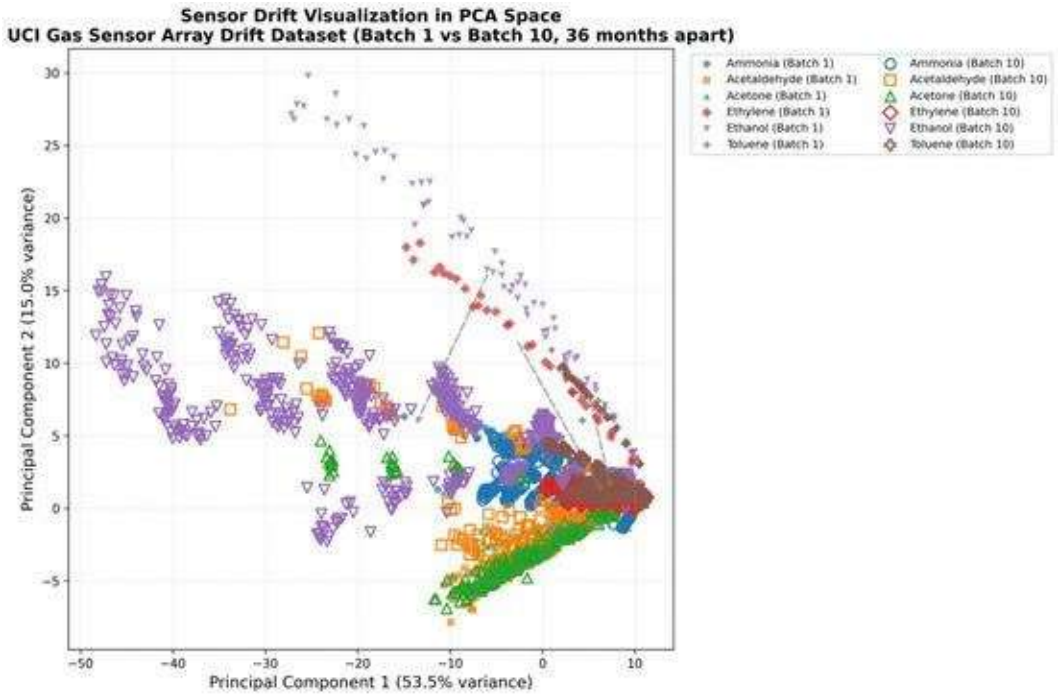


- WetLab
- DryLab
- Human Practace
- Project Design
- Website develop
- Value Present
- English Presentation
- Experiment Result

電子鼻氣味診斷


核心感測技術
核心感測技術
農業病蟲害監測
Fruit flies
Pest VOCs
Manga tree
Bio-Nose
Handheld
農業病蟲害監測
偵測受害作物釋放的氣味
呼氣疾病診斷
Disease
VOCs
Bio-Nose
Breathalyzer
Diagnostic Report
呼氣疾病診斷
分析呼吸中的健康標記
樣品與空氣品質
Gas
from
bag.
Air sample
bag
Bio-Ncse
Laboratory System
Factory
樣品與空氣品質
檢查純度與環境品質

感測器漂移：持續且昂貴的問題



重新校正為何難以擴展

- 漂移並非一次性異常
- 校正必須持續進行
- 每次重新校正都需要完整且標註良好的資料集
- 真正的成本來自校正頻率，而非單次校正

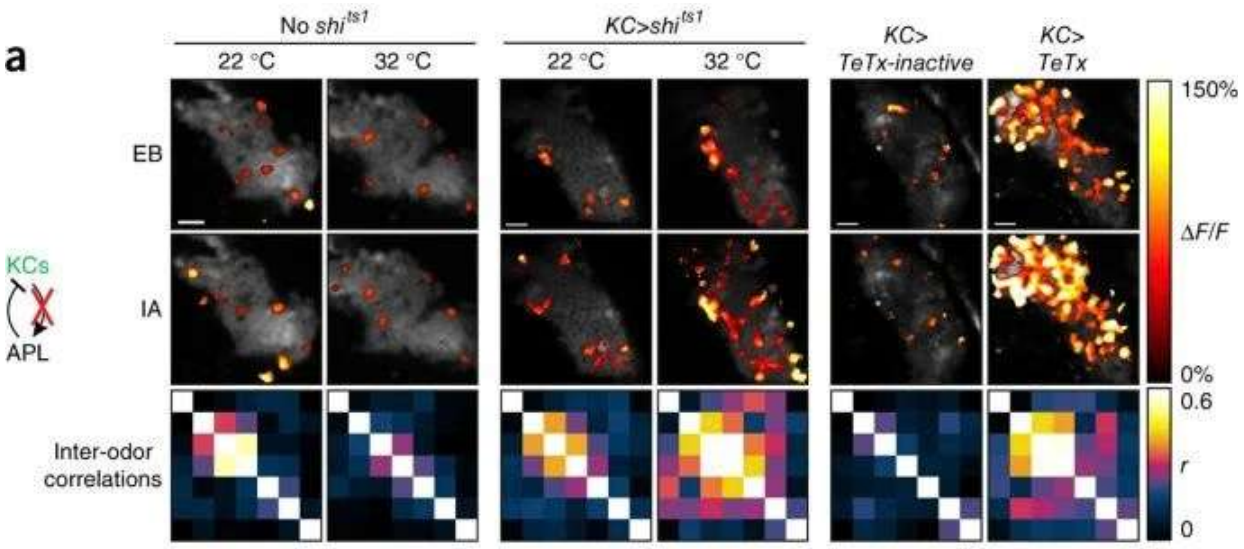
生物藍圖：昆蟲嗅覺提供穩定且強健的氣味編碼機制

增益正規化可維持稀疏編碼穩定

- APL 神經元會正規化 Kenyon cell 活動，使稀疏氣味表徵在不同氣味濃度下保持穩定

稀疏且去相關的編碼可提升辨識能力

- 蕈狀體中的稀疏化與去相關化可強化學習後的氣味辨識，並降低氣味間的混淆



側向抑制與適應機制共同作用

- 神經迴路層級的側向抑制搭配細胞適應，將密集編碼轉換為稀疏且去相關的表示

生物藍圖：昆蟲嗅覺提供穩定且強健的氣味編碼機制

增益正規化可維持稀疏編碼穩定

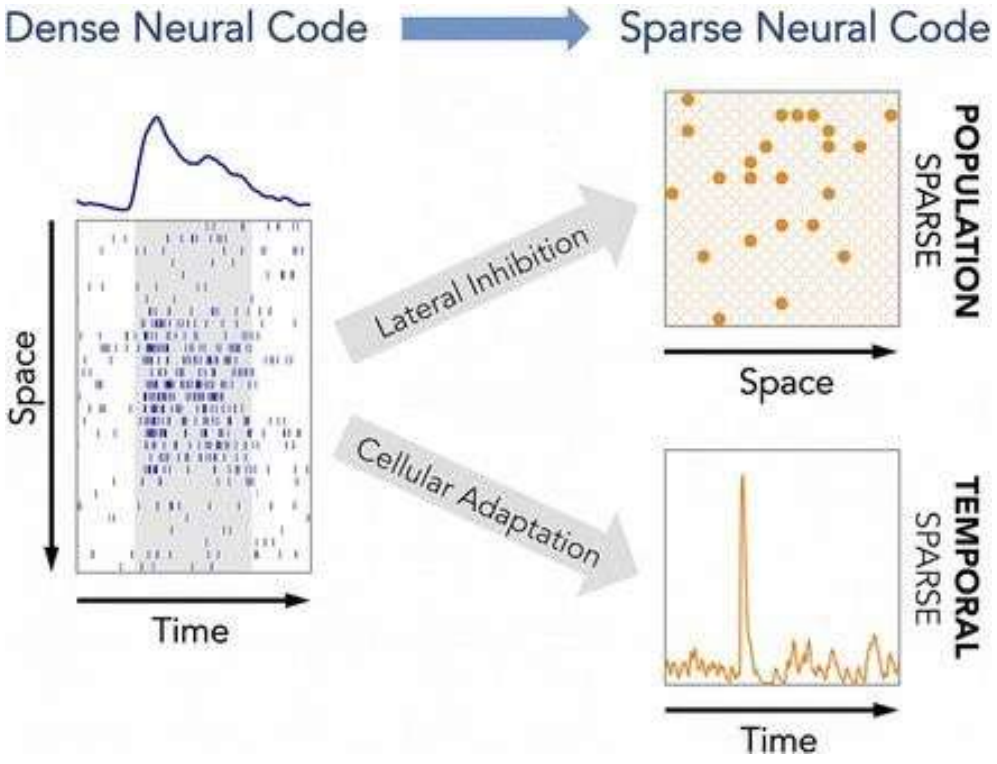
- APL 神經元會正規化 Kenyon cell 活動，使稀疏氣味表徵在不同氣味濃度下保持穩定

稀疏且去相關的編碼可提升辨識能力

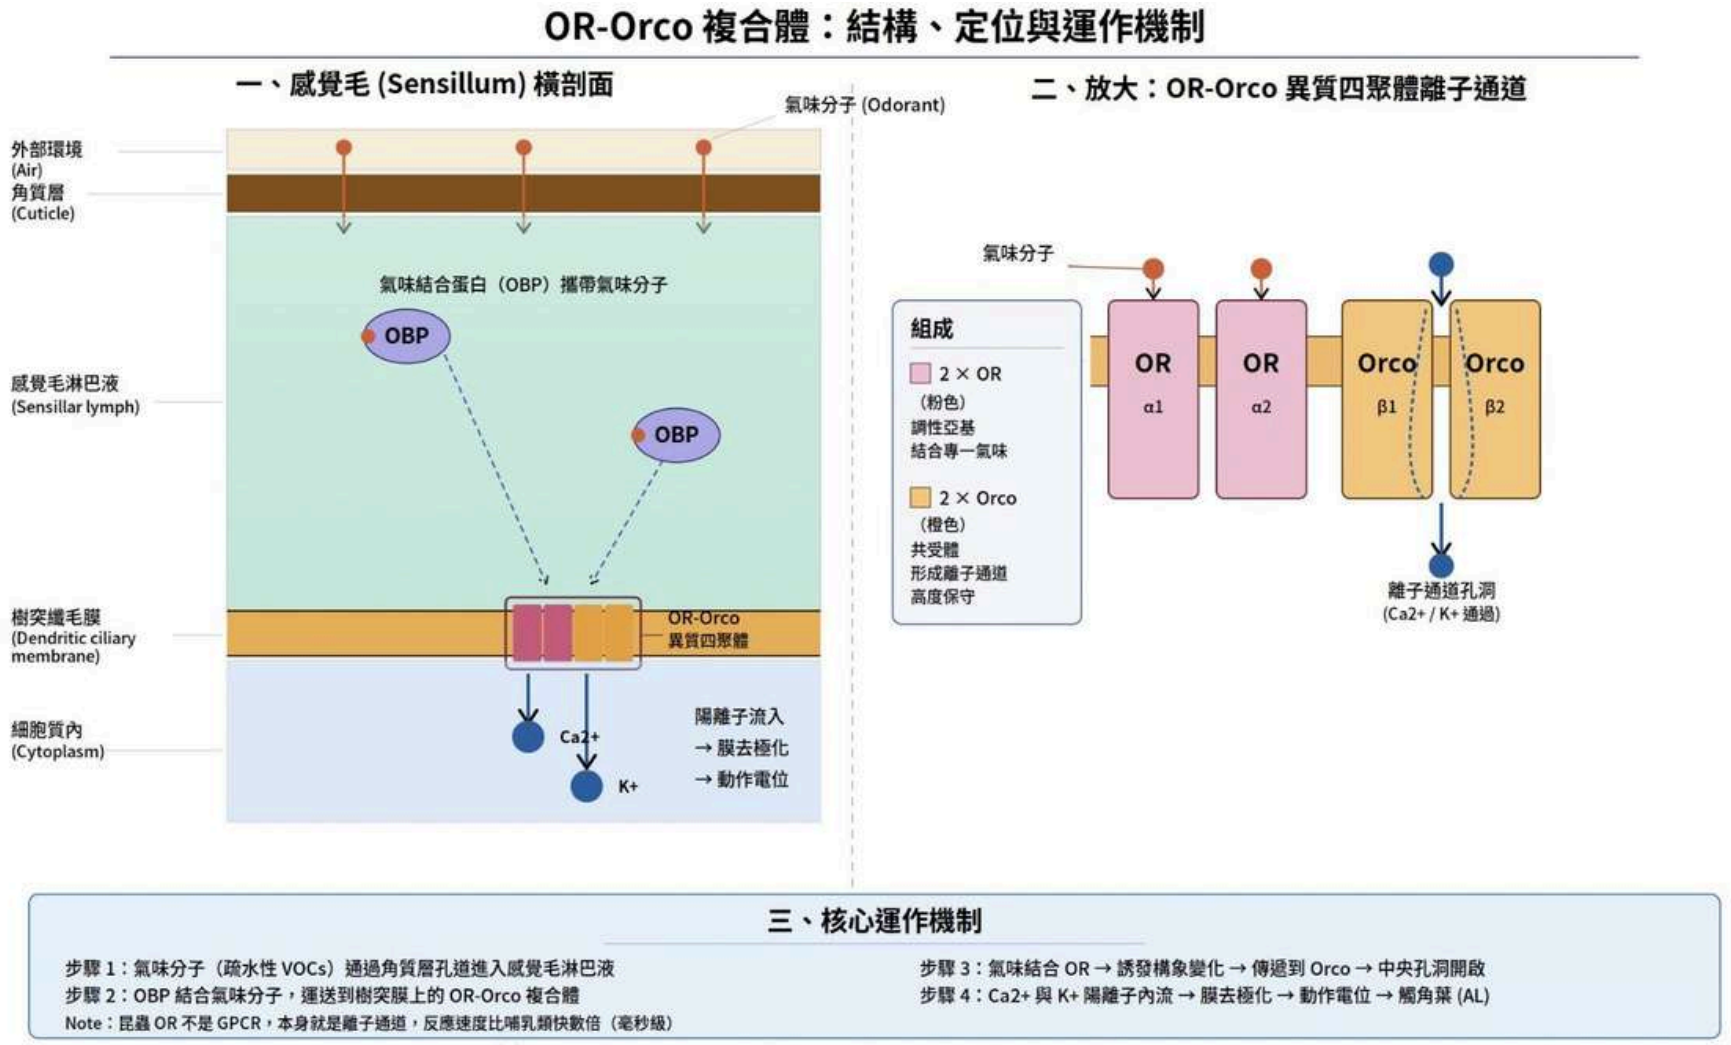
- 蕈狀體中的稀疏化與去相關化可強化學習後的氣味辨識，並降低氣味間的混淆

側向抑制與適應機制共同作用

- 神經迴路層級的側向抑制搭配細胞適應，將密集編碼轉換為稀疏且去相關的表示

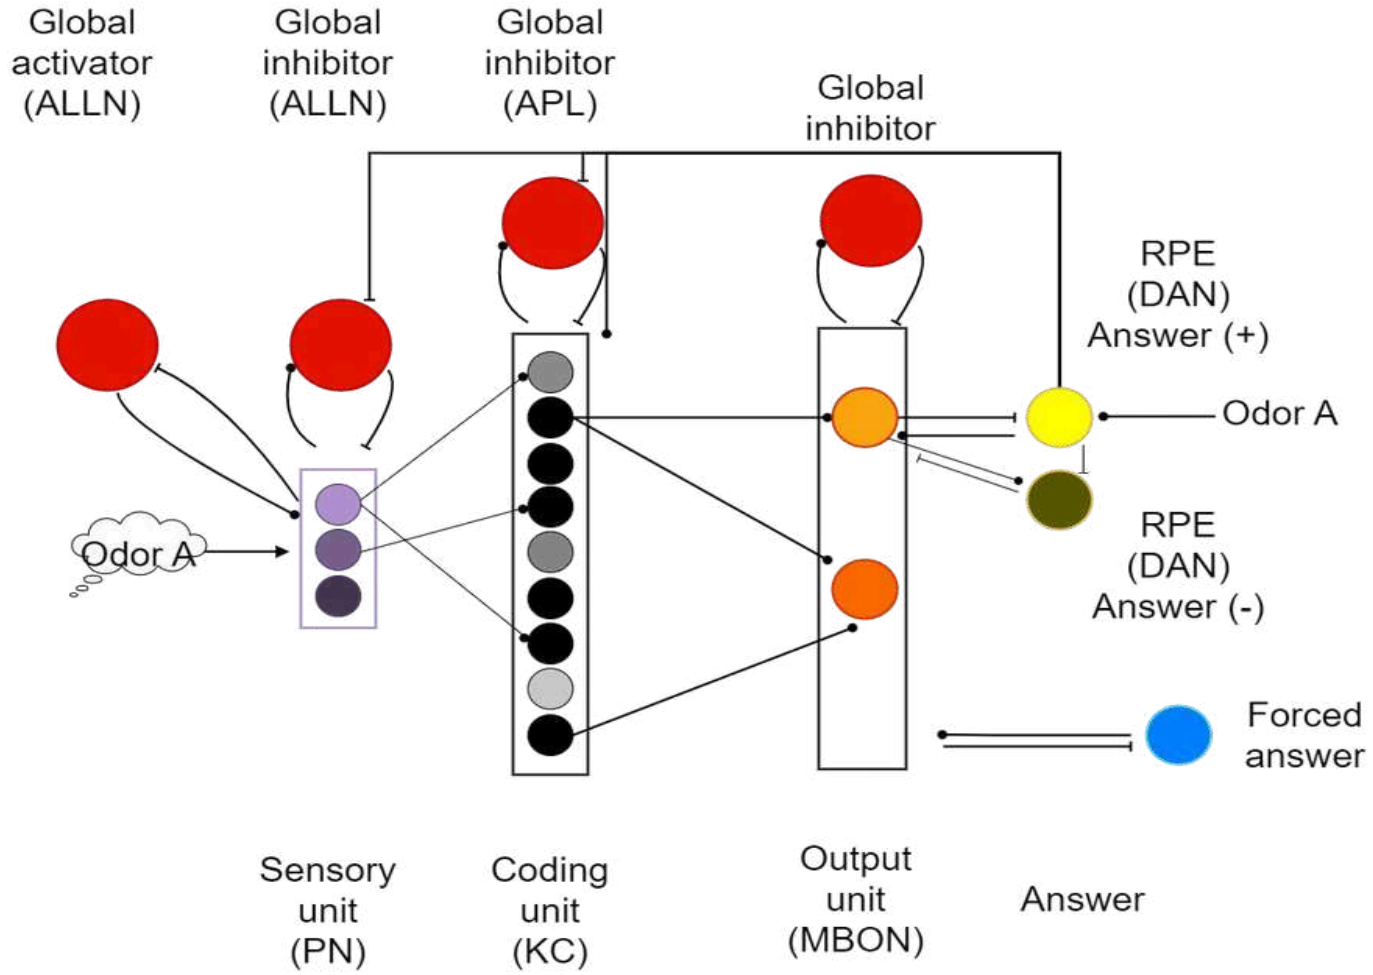


Igem Wetlab : 用細胞當作氣體感測器

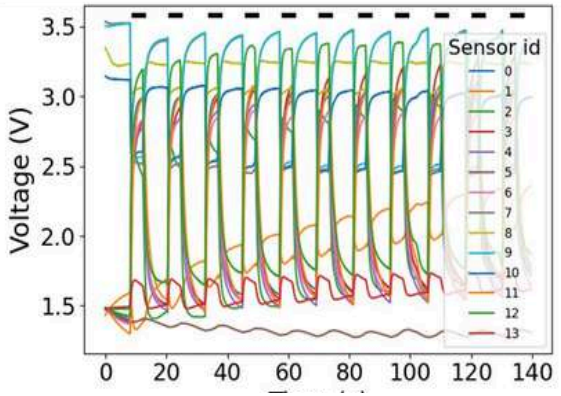


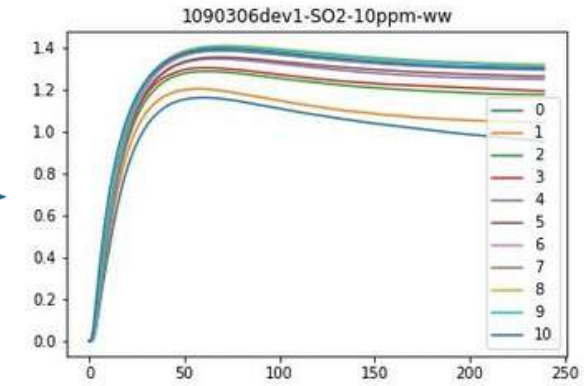
Igem Drylab系統架構： 蕈狀體 啟發的脈衝神經網路

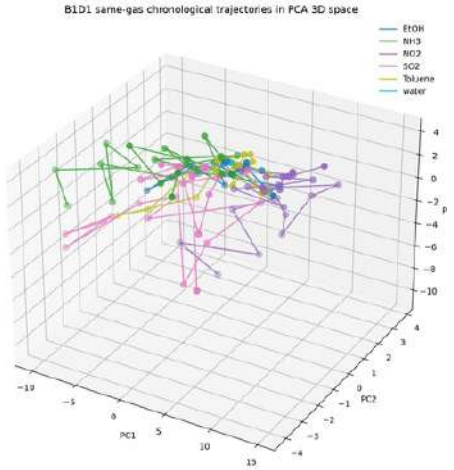
稀疏編碼與側向抑制 產生穩定且抗漂移的氣味編碼

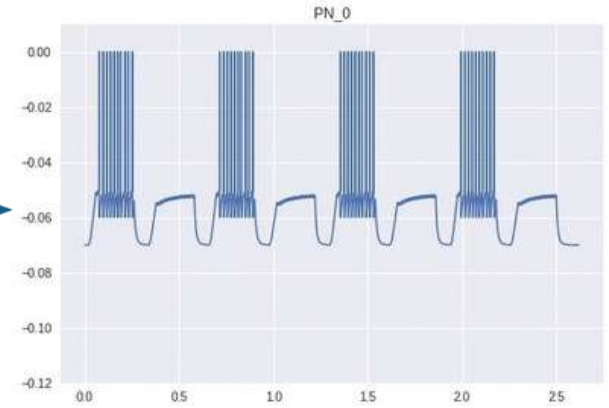


從原始感測器訊號到脈衝式氣味編碼的處理流程







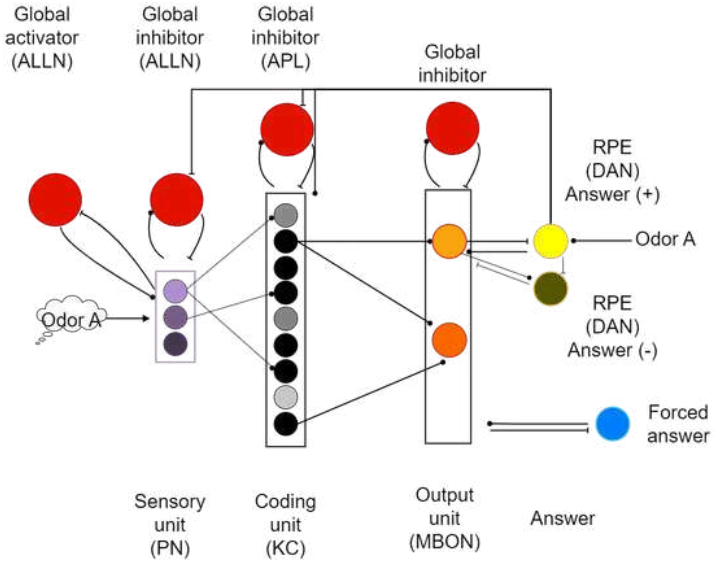


NO2, SO2, NH3,Toluene,
與 EtOH 14 個電子氣體感測器

PCA 用於降低資料維度

重複訓練

(



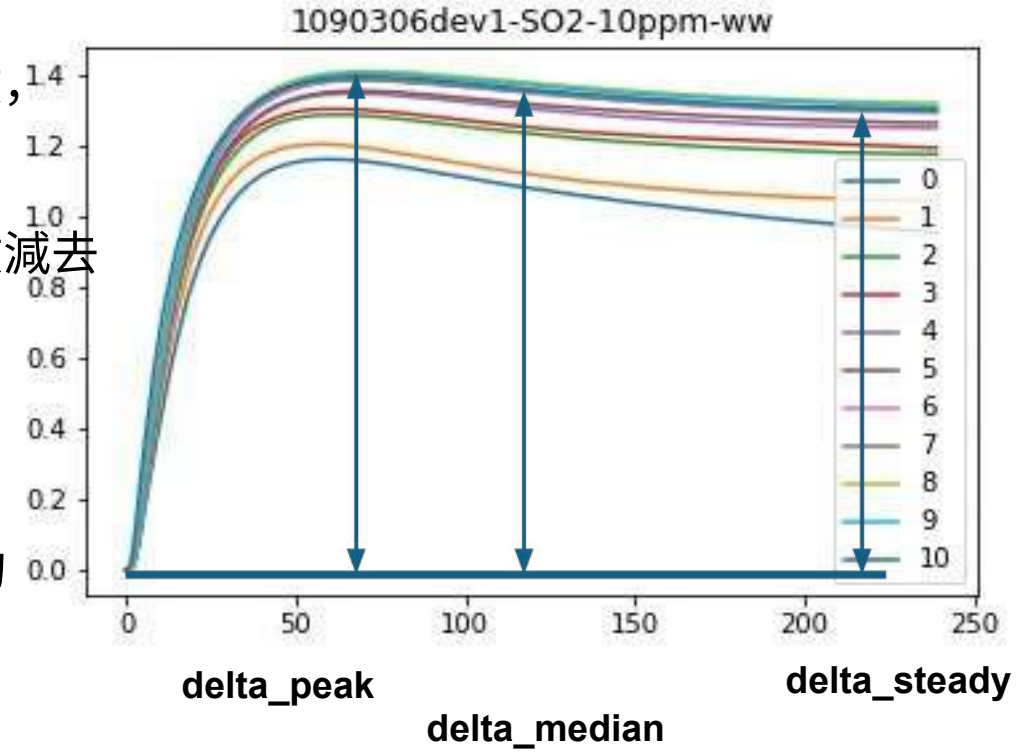
學習機制:
1. STDP
2. Synaptic homeostasis
→ weight normalization
→Pre/post
3. Intrinsic plasticity

)

氣體資料六種特徵

各特徵的計算方式

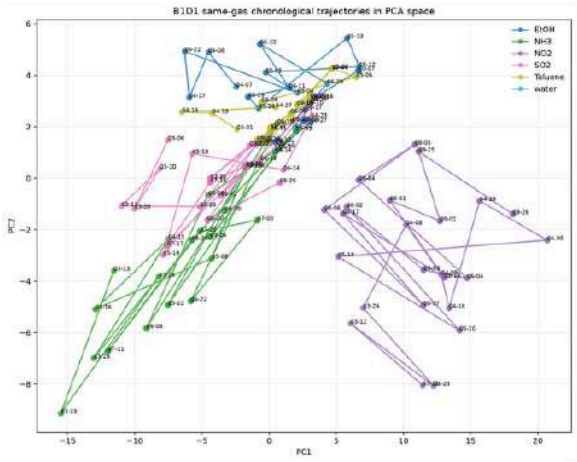
- 基準值：前一段 *Dilute*（乾淨空氣）最後 60 個取樣點的中位數，各感測器分別計算
- **delta_median**：整體位移，整段 *Test*（暴露）視窗的中位數減去基準值
- **delta_steady**：穩態反應，取 Test 視窗最後 *60* 個取樣點的中位數，捕捉暫態消退後的平台區
- **delta_peak**：帶正負號的峰值反應，取暴露期間相對基準值的最大絕對偏差，並保留方向
- **relative_***：上述三種 delta 分別除以 |baseline|，修正不同感測器與裝置間的基準偏移，再交由 PCA 處理

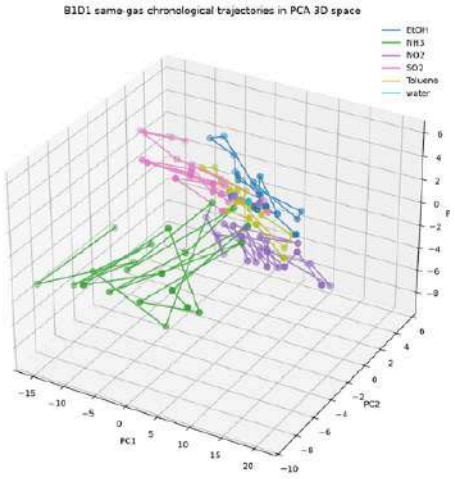


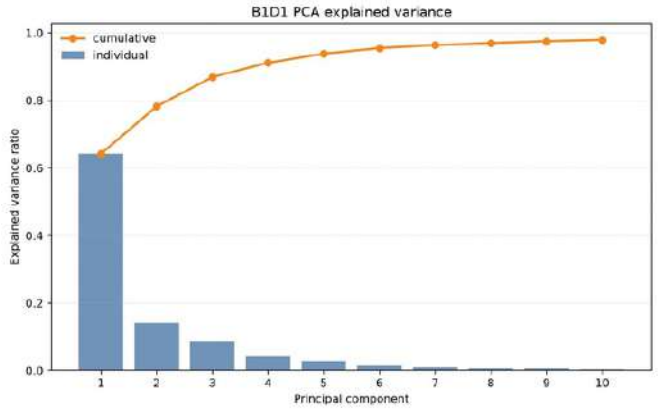
資料前處理

從 **14** 維感測器空間到固定 **PN** 層

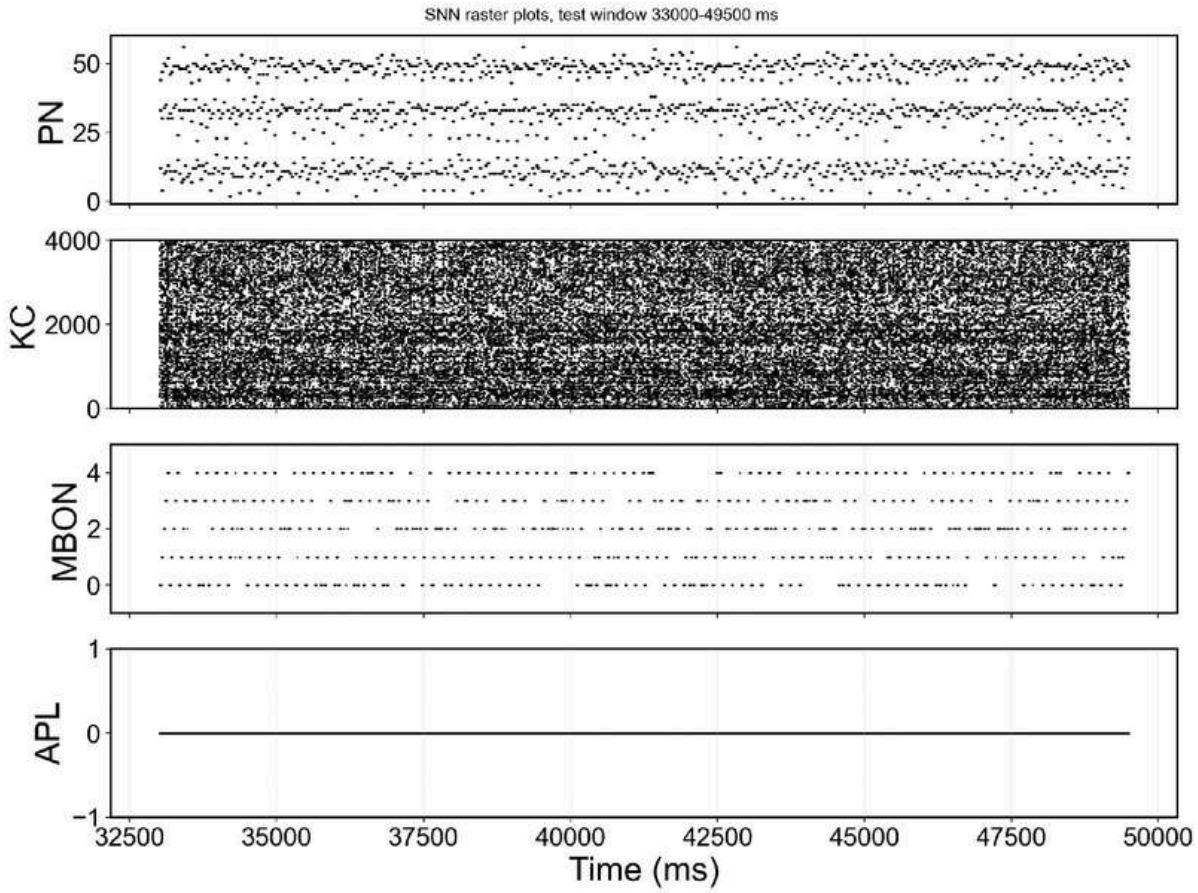
- 輸入：每個感測器提供一個 delta_peak 值，每次氣味試驗形成 14 維向量
- 僅以訓練集擬合：PCA 僅以訓練資料擬合，再套用於訓練集與測試集
- **8** 個主成分保留約 **99.5%** 變異：PC1 單獨解釋約 74%，前 8 個主成分幾乎涵蓋全部訊號（PC1=0.74、PC2=0.14、PC3=0.06，累積約 0.995）







SNN 最佳效能



參數：

- PCA-8, p_pn_kc=0.05, w_apl_kc=30, ip=2, KC=1000, w_kc_mbon=10, lateral=2000, learning_rate=0.025

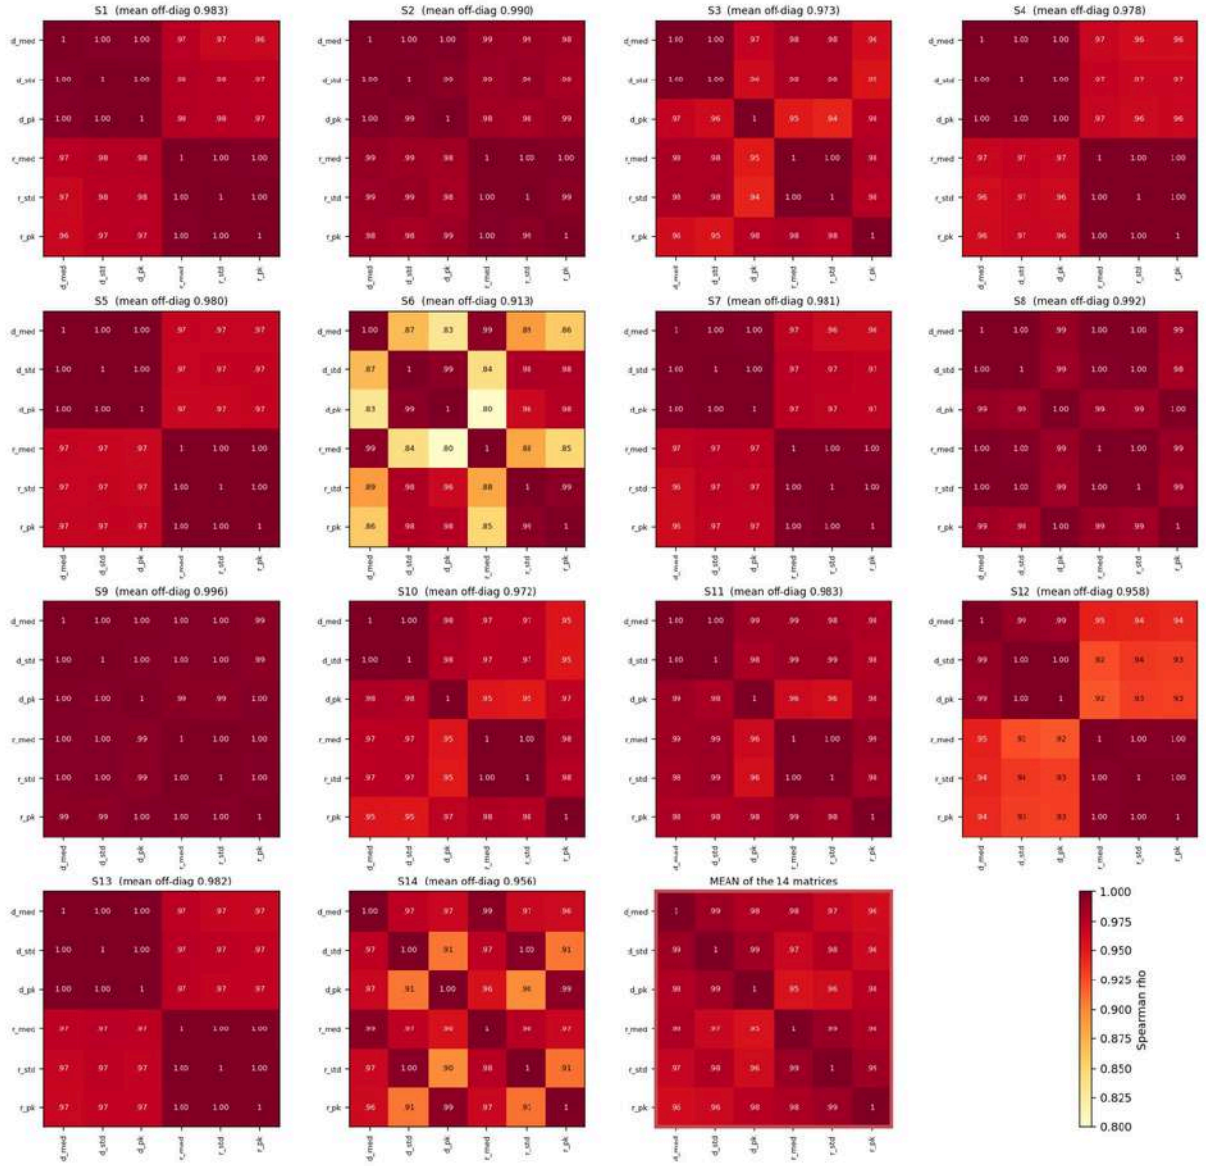
效能：

- MBON 讀出層 accuracy=0.860

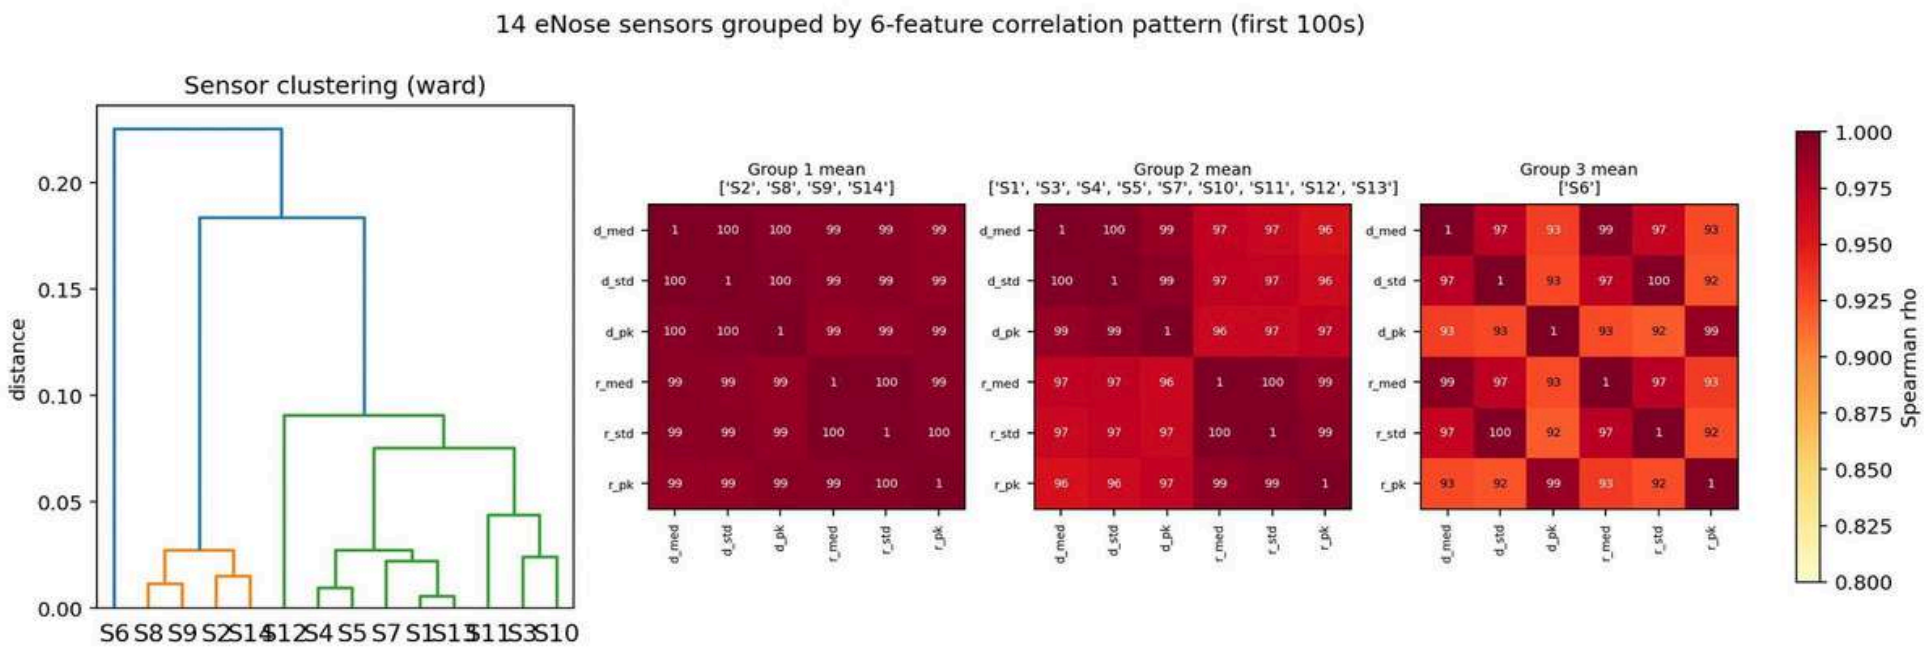
六種特徵真的彼此獨立嗎?

相關矩陣顯示的結果

- **14** 個感測器的平均結果（右下矩陣）顯示，非對角線相關係數幾乎都高於 0.9
- 兩個感測器較為特殊：S6（平均 ρ = 0.913）與 S12（平均 ρ = 0.958）的原始特徵（d_*）與相對特徵（r_*）之間相關 性明顯較低

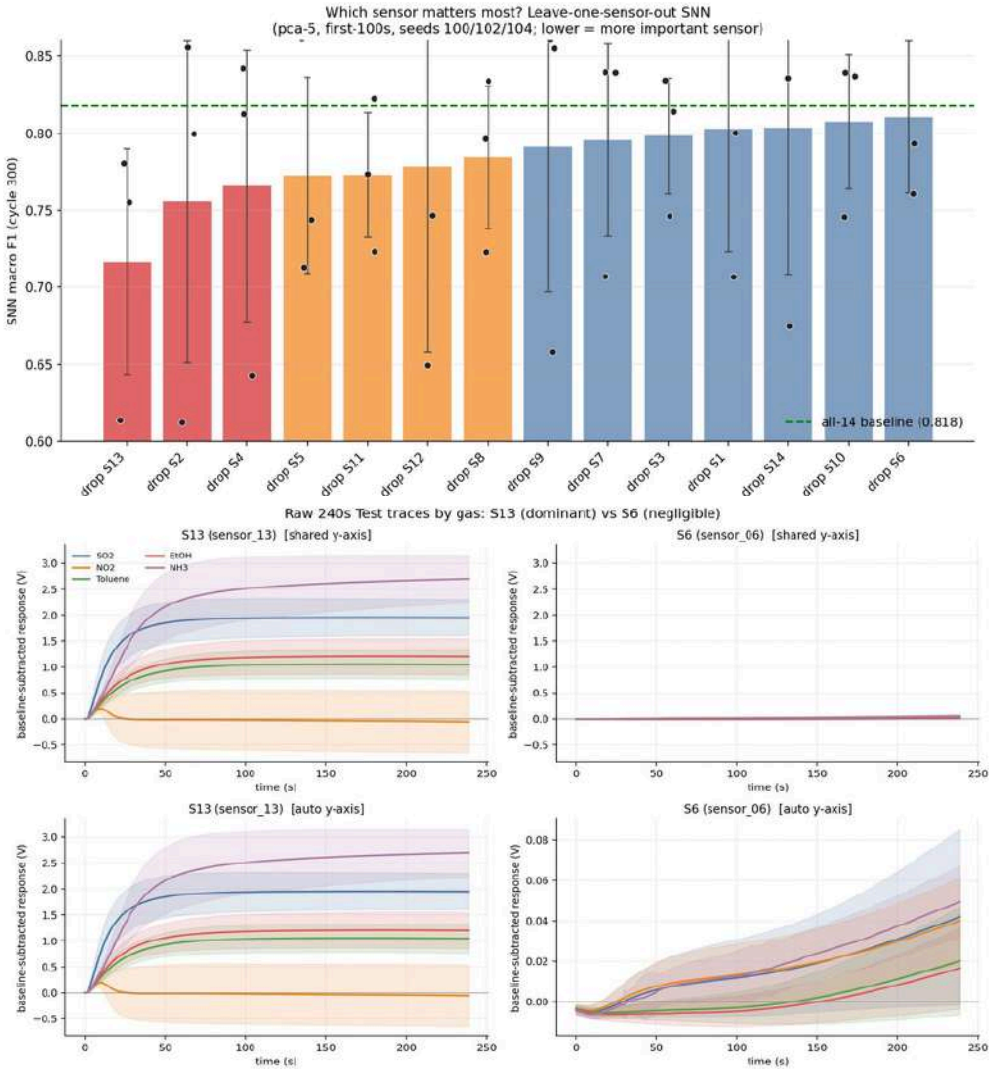


三種感測器類型，而非十四種



- 第1組：S2、S8、S9、S14：幾乎完全重複，六種特徵近乎可互換（ρ≈99–100）
- 第2組：S1、S3、S4、S5、S7、S10、S11、S12、S13：仍高度相關（ρ≈96–100），模式略弱但一致
- 第3組：S6：在樹狀圖最大連結距離處分離，是明顯離群值；d_pk/r_pk 與其他特徵的相關性較低

消融研究



- 逐一移除感測器的消融實驗：逐一移除感測器並重新訓練，以14 個感測器的基準結果比較 macro F1
- **S13** 最重要：移除後 F1 降至約 0.72，是單一感測器移除造成的最大損失
- **S6** 最不重要：移除後 F1 約為 0.81，等於或高於基準；模型幾乎沒有損失

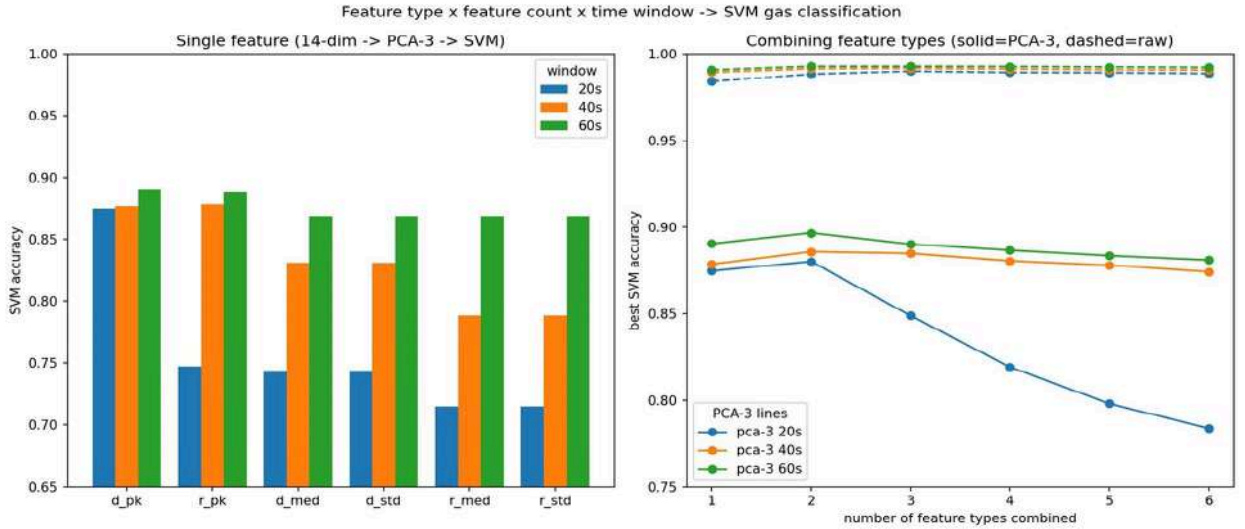
原因

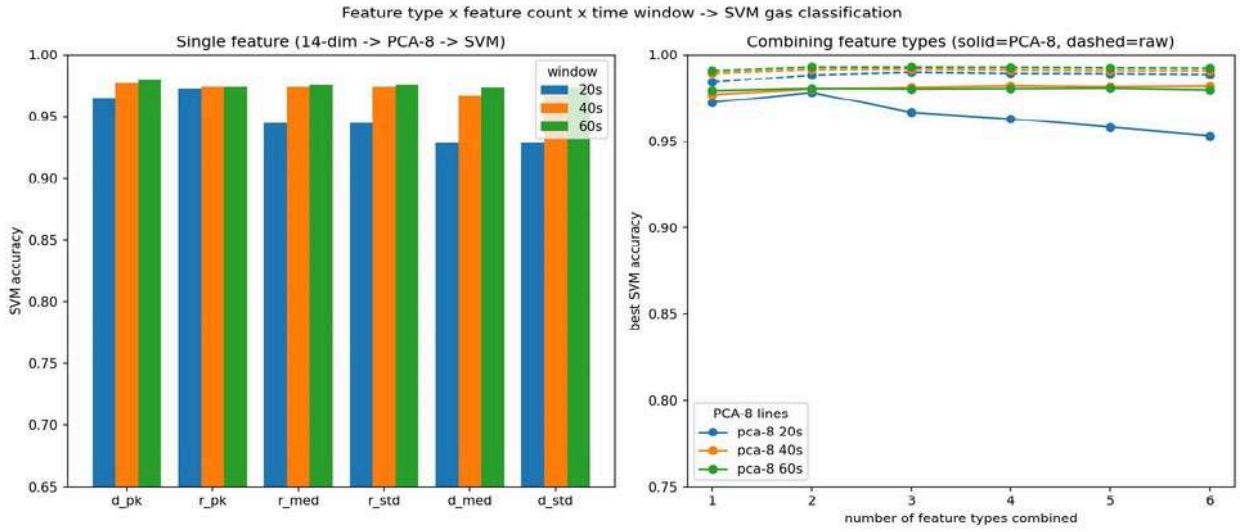
- 240秒原始反應曲線直接解釋差異：S13 對 5 種氣體皆呈現強且分離良好的反應；S6 對所有氣體的原始反應幾乎平坦（即使自動縮放仍 <0.1V）

更多特徵未必更好

SVM 評估結果

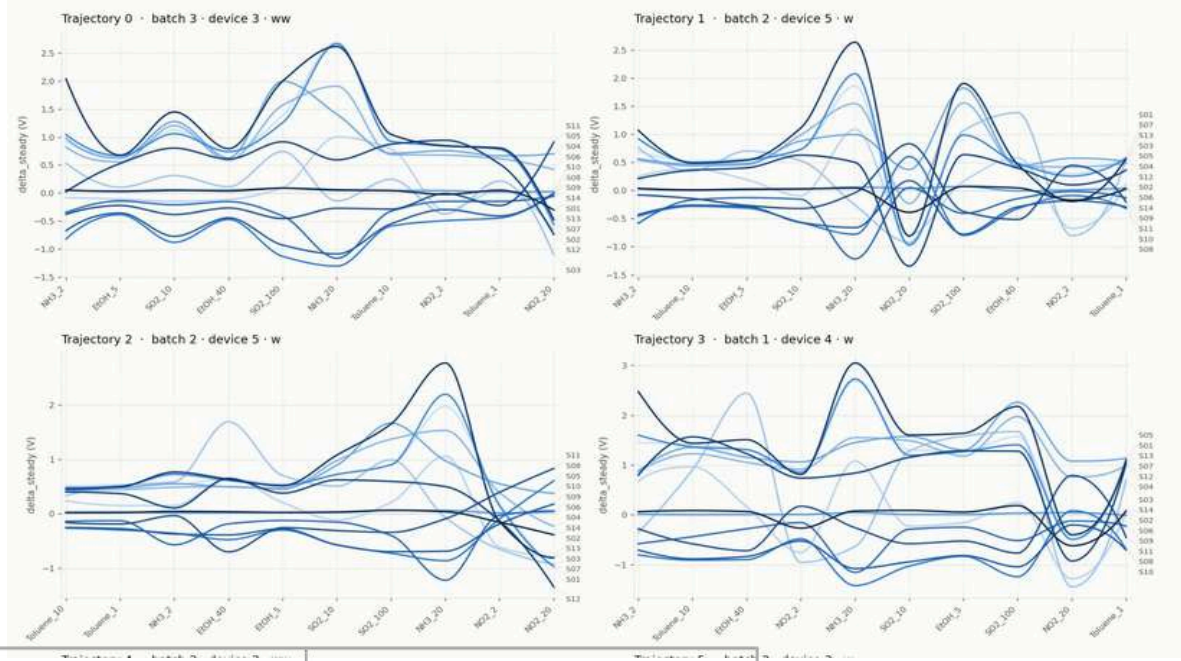
- **delta_peak**是最佳單一特徵：delta_peak 與 relative_delta_peak 在所有時間窗皆優於 median／steady-state 特徵
- 瓶頸在壓縮，而非特徵：使用未壓縮的原始組合特徵取代 PCA-3，無論組合多少種特徵，準確率皆接近上限（約 0.99）





泛化至真實連續氣味暴露

Bootstrap 重抽樣真實資料，提供更困難且貼近實務的測試



SVM 評估

- 目的：SNN 僅以獨立單次暴露訓練；軌跡測試其能否泛化至訓練時未見的保留連續多氣味暴露
- 即使軌跡中會切換不同氣味，SNN 對每次暴露的分類準確率約在 75%附近。

	delta_steady	delta_peak
準確率	64.9%	75.0%
F1 分數	0.633	0.739
錨點準確率	75.0%	85.0%
暫態點	61.1%	71.3%

Per aspera ad astra



法國巴黎國際會議中心

下一站，**Paris 2026**

@IGEM_TSINGHUA



謝謝聆聽